

# Implementation – Email Classification using Transformers

Tim Terbach

June 2025

## Contents

<b>1</b>	<b>Einleitung</b>	<b>2</b>
1.1	Projekt . . . . .	2
<b>2</b>	<b>Projektstruktur</b>	<b>2</b>
2.1	Frontend . . . . .	2
2.2	Backend . . . . .	3
2.2.1	REST-API . . . . .	3
2.2.2	Docker . . . . .	3
<b>3</b>	<b>Trainingsdaten</b>	<b>4</b>
3.1	E-Mail Generierung mit der ChatGPT API . . . . .	4
3.1.1	User Prompt . . . . .	5
3.1.2	Generierter Datensatz . . . . .	6
<b>4</b>	<b>Fine Tuning</b>	<b>7</b>
4.1	Erste Schritte . . . . .	7
4.2	Auswahl des BERT-Modells . . . . .	8
4.3	Modell auf Training vorbereiten . . . . .	8
4.4	Trainingsdaten vorbereiten . . . . .	9
4.5	Metriken definieren . . . . .	10
4.6	Training des Modells . . . . .	10
<b>5</b>	<b>Auswertung</b>	<b>12</b>
5.1	Allgemeine Metriken . . . . .	12
5.2	Label-spezifische Metriken . . . . .	12
<b>6</b>	<b>Weitere Verbesserungen</b>	<b>13</b>
6.1	Verbesserter User Prompt . . . . .	13
6.2	Auswertung . . . . .	15
6.3	Allgemeine Metriken . . . . .	15
6.4	Label-spezifische Metriken . . . . .	16
<b>7</b>	<b>Fazit, Herausforderungen und Ausblick</b>	<b>17</b>
7.1	Projektzusammenfassung . . . . .	17
7.2	Persönliche Lernerfolge . . . . .	17
7.3	Ausblick und zukünftige Verbesserungen . . . . .	17

# 1 Einleitung

Nachdem in der theory.pdf verallgemeinert die theoretischen Grundbausteine dieses Projekts erklärt wurden, beschäftigt sich diese Datei nun mit der konkreten Anwendung dieses Wissens zum Lösen eines praktischen Problems.

## 1.1 Projekt

In diesem Projekt wollen wir das Postfach eines Versicherungsunternehmens simulieren. Genauer sollen dabei eingehende E-Mails in fünf verschiedene Kategorien eingeordnet werden:

1. Kfz-Schaden
  - Unfall, Blebschaden, Wildunfall
2. Hausrat-Schaden
  - Einbruch, Wasserschaden, Brandschaden
3. Haftpflicht
  - versehentliche Beschädigung fremder Dinge
4. Reiseschaden
  - Gepäckverlust, Stornierung, Krankheit im Urlaub
5. Tierkrankheit
  - OP beim Haustier, Tierarztrechnung

Anschließend können diese E-Mails dann den richtigen Sachbearbeitern zugeordnet werden. Da es sich hierbei um ein Demoprojekt handelt, werden diese zu klassifizierenden E-Mails eine verhältnismäßig einfache Struktur haben und sich inhaltlich pro Label auf die 2-3 vordefinierten Themen orientieren

---

## 2 Projektstruktur

An dieser Stelle gehen wir kurz auf die allgemeine Projektstruktur ein, sowie die gewählten Architekturen und Technologien.

```
VectorMail/  
  api/           # Spring Boot backend (REST API)  
  frontend/      # Vue.js frontend (Vite)  
  python-service/ # Python-based classification module (Flask)  
  docs/          # Theory and implementation details  
  docker-compose.yml # Launches the Flask engine container  
  README.md      # Project overview
```

### 2.1 Frontend

Das Frontend wird mit Vue.js entwickelt und soll sich durch ein verspieltes, dennoch übersichtliches und intuitives Design auszeichnen.

Beim Styling habe ich mich für die BEM-Syntax entschieden, um ein besseres Verständnis für CSS-Prinzipien zu erlangen und gleichzeitig eine professionelle Benennung meiner CSS Elemente zu garantieren.

Für mehr Informationen betrachten Sie die README.md des frontend-Verzeichnisses.

## 2.2 Backend

Das Backend wird als REST-API umgesetzt und übernimmt das Klassifizieren der E-Mails mithilfe unseres trainierten LLMs. Es wird in einem Docker-Container mit Flask betrieben, um eine isolierte, skalierbare und leicht wartbare Architektur zu gewährleisten. Python wurde als Programmiersprache für das Training von BERT gewählt, da es weit verbreitet in KI-Anwendungen und Algorithmik ist und ich zudem meine Python-Fähigkeiten ausbauen möchte.

### 2.2.1 REST-API

Die REST-API dient als Schnittstelle zwischen dem Client und dem Backend. Der erste implementierte Endpunkt ist eine POST-Request, die die Wahrscheinlichkeiten der definierten Labels zurückgibt. Dabei dient das Backend (Spring Boot) als Vermittler zwischen Client und unserem Docker-Container, welcher das Python-Skript beinhaltet. Dort wird die eigentliche Klassifizierung durchgeführt.



Figure 1: Symbolische Darstellung der Kommunikation

### 2.2.2 Docker

Um eine modulare und leicht wartbare Architektur sicherzustellen, wird das Python-Programm, wie bereits erwähnt, in einem separaten Docker-Container betrieben.

Zunächst habe ich mich auch in diesem Projekt für `python:3.10-slim-buster` als Image entschieden, da es bereits in vorherigen Projekten Probleme mit dem schlankeren `python:3.10-slim` gab.

Um dafür zu sorgen, dass sich der Docker-Container selbstständig aktualisiert, Änderungen also selbstständig übernommen werden, ohne den Container mit `docker-compose up` neu bauen zu müssen, habe ich mich hier dafür entschieden diese Funktion mithilfe von Volumes zu ermöglichen.

Durch die Erweiterung der `docker-compose.yml` um

```
volumes:  
- ./python-service:/app
```

erkennt der Docker-Container nun, falls Änderungen innerhalb des "python-service"-Verzeichnisses vorgenommen werden und startet den Container automatisch neu.

### 3 Trainingsdaten

Um BERT zu fine-tunen brauchen wir zunächst Trainingsdaten. Zum Start wollen wir dabei mit etwa 400 E-Mails pro Label beginnen. Da es keine passende Datenbank gibt, die E-Mails zu diesen Kategorien liefert, habe ich mich an dieser Stelle dazu entschieden diese von einem weiteren, generativen LLM erzeugen zu lassen, in diesem Fall ChatGPT 4.1. Bei einer Menge von insgesamt 2000 E-Mails müssen wir dabei jedoch einen anderen Ansatz wählen, als einfach chat.openai.com zu öffnen und nach 2000 E-Mails zu diesen Labels zu fragen. Wir nutzen hier die sehr einfache API von ChatGPT, um per Python-Skript diese E-Mails zu generieren. Obwohl dieser Schritt bei der Planung des Projektes zunächst nicht angedacht war, dient er als perfekte Erweiterung des Projektes, da wir auch hier weitere Konzepte aus der theory.pdf aufgreifen.

#### 3.1 E-Mail Generierung mit der ChatGPT API

Betrachten wir zunächst mal das Python-Skript, welches wir zur Generierung verwenden werden, genauer die `generate_email()` Funktion, welche iterativ ausgeführt wird und somit immer wieder neue E-Mails liefert.

```
def generate_email():
    response = client.chat.completions.create(
        model="gpt-4.1",
        messages=[
            {"role": "system", "content": "Du bist ein Generator für realistische, formelle E-"},
            {"role": "user", "content": base_prompt}
        ],
        temperature=0.8
    )
    text = response.choices[0].message.content
    try:
        return json.loads(text)
    except:
        print("Fehler beim Parsen der Antwort:")
        print(text)
        return None
```

Diese Funktion ist relativ intuitiv und bedarf keiner großartiger Erklärung, interessant sind jedoch vor allem die Parameter

- `temperature=0.8`
- `messages= [ "role": "system", "content": "Du bist ein Generator für realistische, formelle E-Mails an eine Versicherung. Gib nur JSON zurück.", "role": "user", "content": base_prompt ],`

Die **temperature** sagt hierbei aus, wie zufällig das Modell bei der Tokengenerierung vorgehen soll. Bei einer Temperature von 0.0 würde das Modell immer nur den wahrscheinlichsten nächsten Token wählen, bei einem gleichbleibenden Prompt würde somit auch der Output bzw. die Sequenz generierter Tokens gleich bleiben, das wollen wir hier natürlich verhindern. Mit einem temperature-Wert von 0.8 sagen wir dem Modell also, dass es auch Tokens wählen darf, welche nicht am wahrscheinlichsten von allen Tokens als nächste vorkommen, um eine hohe Variation an verschiedenen E-Mails zu erzeugen.

Ein weiterer interessanter Punkt sind die übergebenen **messages**. Mit **messages** wird jeweils eine Rolle sowie ein Prompt (Content) übergeben. Dabei legen wir mit **role="system"** fest, dass es sich um einen System-Prompt handelt. Hier wird dem Modell kurz und knapp gesagt, wie es sich verhalten soll, in unserem Fall legen wir hier vor allem fest, dass das Modell nur mit einer JSON antworten soll, da wir mehr Output hier nicht brauchen, bzw. dieser zusätzliche Output mit mehr Tokens und somit höheren Kosten verbunden wäre.

Anschließend übergeben wir den eigentlichen Nutzer-Prompt, dementsprechend mit `role="user"`. Dieser Prompt bezieht sich vor allem auf ein paar inhaltliche Richtlinien und Beispiele der E-Mails für die verschiedenen Labels. Den kompletten User-Prompt hat dabei ChatGPT selbst auf Basis dieser Richtlinien und Beispiele erstellt, mit dem Ziel ein weiteres LLM dazu anzuweisen, einen für diese Aufgabe optimalen Datensatz zu erzeugen, diesen können Sie in dem folgenden Abschnitt betrachten.

### 3.1.1 User Prompt

Bitte generiere jeweils genau **eine E-Mail** für jedes Label im folgenden JSON-Format:

```
[
  {
    "label": "<schadenstyp1>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp2>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp3>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp4>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp5>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
]
```

#### Regeln:

1. Die E-Mail soll **formell, aber alltagsnah** klingen – wie eine echte Nachricht von Privatpersonen oder Kunden.
2. Der E-Mailtext soll **3–4 Sätze** lang sein, in natürlichem Deutsch.
3. Verwende **keine sensiblen Daten** wie echte Adressen, Telefonnummern oder reale Versicherungsnummern.
4. Die E-Mail soll **thematisch zum jeweiligen Schadenstyp passen**, ohne zu ausschweifend oder künstlich zu wirken.
5. Verwende **normale, höfliche Sprache**, gerne mit kleinen individuellen Variationen im Ausdruck.
6. Gib **nur die Keys label und text** zurück – keine Metadaten, Überschriften oder Kommentare.

#### Mögliche Labels (zufällig auswählen):

- "kfz-schaden" → z. B. Unfall, Blebschaden, Wildunfall
- "hausrat-schaden" → z. B. Einbruch, Wasserschaden, Brandschaden
- "haftpflichtschaden" → z. B. versehentliche Beschädigung fremder Dinge

- "reiseschaden" → z. B. Gepäckverlust, Stornierung, Krankheit im Urlaub
- "tierkrankheit" → z. B. OP beim Haustier, Tierarztrechnung

#### **Thematische Richtlinien für jede Kategorie:**

##### **Kfz-Schaden:**

- Betreff: Schäden an Autos oder Motorrädern
- Typische Begriffe: Unfall“, Fahrzeug“, Blechschaden“, Wild“, Polizei“

##### **Hausrat-Schaden:**

- Betreff: Schäden am Inventar in Wohnung oder Haus
- Typische Begriffe: Einbruch“, Rohrbruch“, Fernseher“, gestohlen“

##### **Haftpflichtschaden:**

- Betreff: Absender hat Dritten Schaden zugefügt
- Typische Begriffe: versehentlich“, mein Kind“, beschädigt“, Nachbar“

##### **Reiseschaden:**

- Betreff: Probleme im Urlaub, z. B. Verlust, Krankheit
- Typische Begriffe: Koffer“, Flug“, Storno“, Rechnung“, Ausland“

##### **Tierkrankheit:**

- Betreff: Tierarztkosten, Behandlungen von Haustieren
- Typische Begriffe: Hund“, Katze“, OP“, Tierarzt“, Rechnung“

### **3.1.2 Generierter Datensatz**

Das Generieren von 2000 E-Mails hat auf diese Art und Weise insgesamt knapp \$2.00 gekostet, bei 160000 generierten Tokens. Durch die Formulierung des User-Prompts haben wir nun also 2000 E-Mails in folgender Struktur vorliegen:

```
... ],
[
{
  "label": "kfz-schaden",
  "text": "ich möchte einen Kfz-Schaden melden, der sich gestern an meinem Auto ereignet ...
},
{
  "label": "hausrat-schaden",
  "text": "leider kam es in meiner Wohnung zu einem Wasserschaden durch einen Rohrbruch in der ...
{
  "label": "haftpflichtschaden",
  "text": "mein Sohn hat beim Spielen versehentlich die Fensterscheibe unseres Nachbarn ...
},
{
  "label": "reiseschaden",
  "text": "bei unserer Rückkehr aus dem Urlaub wurde festgestellt, dass unser Koffer am ...
},
{
  "label": "tierkrankheit",
  "text": "unser Hund musste letzte Woche wegen einer akuten Verletzung operiert werden. Die ...
```

```
}  
],  
[...
```

Es fällt auf, dass sich das Modell sehr stark an die vorgegebenen Begriffe gehalten hat, sodass sehr viele E-Mails eine sehr ähnliche Struktur aufweisen. Es lassen sich jedoch später sehr einfach neue E-Mails generieren, in welchen wir den Fokus auf andere Worte und Szenarien legen können, um für eine diversere Trainingsgrundlage zu sorgen und somit Overfitting zu verhindern. Im Rahmen dieses Projektes sollten die generierten 2000 E-Mails jedoch erstmal ausreichen.

---

## 4 Fine Tuning

Nachdem wir nun also unsere E-Mails unter anderem mit Hilfe von System Prompting generiert haben, wollen wir diese Daten für das Fine-Tuning eines BERT-Modells nutzen.

### 4.1 Erste Schritte

Um über Hugging Face auf Modelle zugreifen zu können und diese trainieren zu können, müssen wir zunächst ein paar Bibliotheken importieren:

- `from datasets import DatasetDict, Dataset`  
Die `datasets`-Bibliothek bietet die speziellen Datenstrukturen **Dataset** und **DatasetDict**. Diese sind für das effiziente Management und die Vorverarbeitung großer Textdatensätze optimiert, was die Kompatibilität mit den weiteren Hugging Face Tools stark vereinfacht.
- `from transformers import AutoTokenizer, AutoModelForSequenceClassification, TrainingArguments, Trainer, DataCollatorWithPadding`
  - **AutoTokenizer**: Lädt automatisch den korrekten Tokenizer für ein gewähltes Modell, um Roh-text in für das Modell verständliche numerische IDs umzuwandeln.
  - **AutoModelForSequenceClassification**: Initialisiert das passende vortrainierte Modell (wie BERT) mit einem zusätzlichen Klassifikations-Head, der speziell für Aufgaben wie die E-Mail-Klassifikation trainiert wird.
  - **TrainingArguments**: Definiert alle wichtigen Hyperparameter und Konfigurationen für den Trainingsprozess, wie Lernrate, Batch-Größe und Epochen.
  - **Trainer**: Dies ist die zentrale Klasse, die den gesamten Trainings- und Evaluations-Loop handhabt und die Komplexität des Modells, der Daten und der Optimierung abstrahiert.
  - **DataCollatorWithPadding**: Sorgt dafür, dass die Textsequenzen innerhalb eines Batches auf eine einheitliche Länge gebracht werden (Padding), um sie als Tensoren an das Modell übergeben zu können.
- `import evaluate`  
Die `evaluate`-Bibliothek von Hugging Face ermöglicht den einfachen Zugriff auf eine Vielzahl von Standard-Bewertungsmetriken (z.B. Accuracy, F1-Score). Diese sind entscheidend, um die Leistung des trainierten Modells während und nach dem Fine-Tuning zu beurteilen.
- `import numpy as np`  
NumPy ist die grundlegende Python-Bibliothek für numerische Berechnungen und die Arbeit mit Arrays. Sie wird häufig benötigt, um die numerischen Ausgaben des Modells zu verarbeiten (z.B. Logits in Klassifikations-Labels umzuwandeln) oder für allgemeine mathematische Operationen bei der Metrikberechnung.

## 4.2 Auswahl des BERT-Modells

Zunächst müssen wir uns natürlich die Frage stellen, welches BERT-Modell wir für unser Projekt überhaupt benutzen. Seit seiner Veröffentlichung 2018 gibt es viele abgewandelte oder optimierte Versionen dieses LLMs. Bekannte Beispiele sind dabei:

- **DistilBERT** (Hugging Face): Eine kleinere und schnellere Version von BERT, die durch Destillation trainiert wurde und etwa 95% der Performance des originalen BERT beibehält.
- **RoBERTa** (Meta): Eine robust optimierte Variante von BERT, die durch längeres Training auf mehr Daten und ohne die Next-Sentence-Prediction-Aufgabe eine verbesserte Leistung erzielt.
- **ALBERT** (Google): Eine Lite BERT“-Version, die durch Parameter-Sharing und Embedding-Faktorisierung die Modellgröße drastisch reduziert, während die Performance erhalten bleibt.

Neben Variationen, welche Training und Parameteranzahl optimieren, gibt es auch Varianten, die auf spezifischen Sprachen trainiert wurden, darunter auch **bert-base-german-cased**. Dieses Modell bietet sich für unser Projekt besonders gut an, da es durch seinen deutschen Trainingssatz besonders gut darin ist, den semantischen und kontextuellen Inhalt einer deutschen Textsequenz zu erfassen und zu verstehen – genau das, was wir für dieses Projekt benötigen.

## 4.3 Modell auf Training vorbereiten

Als Erstes laden wir unser Modell und fügen den Classification Head hinzu. Mit Hugging Face und unseren eben getätigten Imports geht das wie folgt:

```
# Pre-trained model path
model_path = "bert-base-german-cased"

# Load tokenizer
tokenizer = AutoTokenizer.from_pretrained(model_path)

# Define label mappings
id2label = {
    0: "Kfz-Schaden",
    1: "Hausrat-Schaden",
    2: "Haftpflichtschaden",
    3: "Reiseschaden",
    4: "Tierkrankheit"
}

label2id = {
    "Kfz-Schaden": 0,
    "Hausrat-Schaden": 1,
    "Haftpflichtschaden": 2,
    "Reiseschaden": 3,
    "Tierkrankheit": 4
}

# Load model with classification head
model = AutoModelForSequenceClassification.from_pretrained(
    model_path,
    num_labels=5,
    id2label=id2label,
    label2id=label2id
)
```



Nachdem wir das Modell nun also mit einem Classification Head versehen haben, müssen wir festlegen, welche Parameter wir während des Trainings anpassen wollen. Wie bereits in der theory.pdf erläutert, werden wir hier nicht nur den Classification Head trainieren, sondern auch die letzten, sogenannten **Pooler Layer** unseres Modells:

```
# Freeze base model parameters
for name, param in model.base_model.named_parameters():
    param.requires_grad = False

# Unfreeze pooler layers
for name, param in model.base_model.named_parameters():
    if "pooler" in name:
        param.requires_grad = True
```

#### 4.4 Trainingsdaten vorbereiten

Da wir nun das entsprechende Modell geladen haben, müssen wir als Nächstes unsere Trainingsdaten aus einer JSON-Datei laden und für das Training vorbereiten.

```
with open("trainingsdata/emails.json", 'r', encoding='utf-8') as f:
    data_from_json = json.load(f)

# Create a Hugging Face Dataset object from the list of email dictionaries
full_dataset = Dataset.from_list(data_from_json)

# Split the dataset into training and validation sets
train_test_split = full_dataset.train_test_split(test_size=0.2, seed=42)

# Wrap both sets in a DatasetDict
dataset_dict = DatasetDict({
    'train': train_test_split['train'],
    'validation': train_test_split['test']
})

# ===== Preprocess Data =====

# Define text preprocessing function
def preprocess_function(examples):
    return tokenizer(examples["text"], truncation=True, max_length=128)

# Tokenize all datasets
tokenized_data = dataset_dict.map(preprocess_function, batched=True, remove_columns=["text"])

# Create data collator
data_collator = DataCollatorWithPadding(tokenizer=tokenizer)
```

Schauen wir uns auch hier die wichtigsten Schritte etwas genauer an.

```
train_test_split = full_dataset.train_test_split(test_size=0.2, seed=42)
```

Hier teilen wir das zuvor erstellte Dataset `full_dataset` in Trainings- und Validierungsdaten auf, um die Modellleistung später evaluieren zu können. Mit `test_size=0.2` legen wir fest, dass 20% der Daten für die Validierung verwendet werden. Durch die Angabe des Seeds bleibt diese Aufteilung reproduzierbar. Die Aufteilung wird anschließend in einer `DatasetDict`-Struktur gespeichert, die später vom `Trainer` erwartet wird.

```
tokenized_data = dataset_dict.map(preprocess_function, batched=True, ...)
```

Hier wenden wir unsere `preprocess_function` mithilfe der `map`-Methode auf die Daten an, um Texte zu tokenisieren und in numerische Formate wie Input-IDs und Attention-Masks umzuwandeln.

Durch das Argument `batched=True` werden mehrere Einträge gleichzeitig verarbeitet, was die Effizienz erhöht.

Zusätzlich entfernen wir unnötige Spalten wie `"text"`, um Probleme beim späteren Padding zu vermeiden. In einem früheren Versuch wurde z.B. versehentlich eine nicht-numerische `"labels"`-Spalte beibehalten, was zu Fehlern beim Collating führte.

```
data_collator = DataCollatorWithPadding(tokenizer=tokenizer)
```

Damit unser Modell effizient in Batches trainieren kann, benötigen wir einen `DataCollatorWithPadding`. Dieser sorgt dafür, dass alle Textsequenzen im selben Batch auf die gleiche Länge gebracht werden.

Das ist nötig, da Modelle wie BERT eine einheitliche Sequenzlänge erwarten, um die Daten als Tensoren verarbeiten zu können.

## 4.5 Metriken definieren

Bevor wir mit dem Training beginnen, sollten wir Metriken definieren, mit denen wir die Modellleistung evaluieren können (z.B. Accuracy, Precision, Recall, F1).

Die konkrete Implementierung dieser Metriken ist in der Datei `python-service/training/training.py` zu finden und wird hier nicht weiter im Detail behandelt.

## 4.6 Training des Modells

Unser Modell ist geladen, der Klassifikations-Head definiert, die zu trainierenden Parameter ausgewählt und die Daten vorbereitet. Nun folgt das eigentliche Training mithilfe von Hugging Face.

Dabei verwenden wir die beiden zentralen Komponenten: `TrainingArguments` zur Konfiguration des Trainings und den `Trainer`, der den Trainingsprozess übernimmt.

```
# Hyperparameter
lr = 2e-5
batch_size = 8
num_epochs = 10

training_args = TrainingArguments(
    output_dir="bert-label-classifier_teacher",
    learning_rate=lr,
    per_device_train_batch_size=batch_size,
    per_device_eval_batch_size=batch_size,
    num_train_epochs=num_epochs,
    logging_strategy="epoch",
    evaluation_strategy="epoch",
    save_strategy="epoch",
    load_best_model_at_end=True,
)

# ===== Define Trainer =====

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=tokenized_data["train"],
    eval_dataset=tokenized_data["validation"],
```


```
tokenizer=tokenizer,  
data_collator=data_collator,  
compute_metrics=compute_metrics,  
)  
  
trainer.train()
```

---

## 5 Auswertung


Nach dem Training auf unseren 2000 Trainingsdaten, betrachten wir nun die definierten Metriken um die Qualität und Funktionalität unseres Modells einzuordnen.

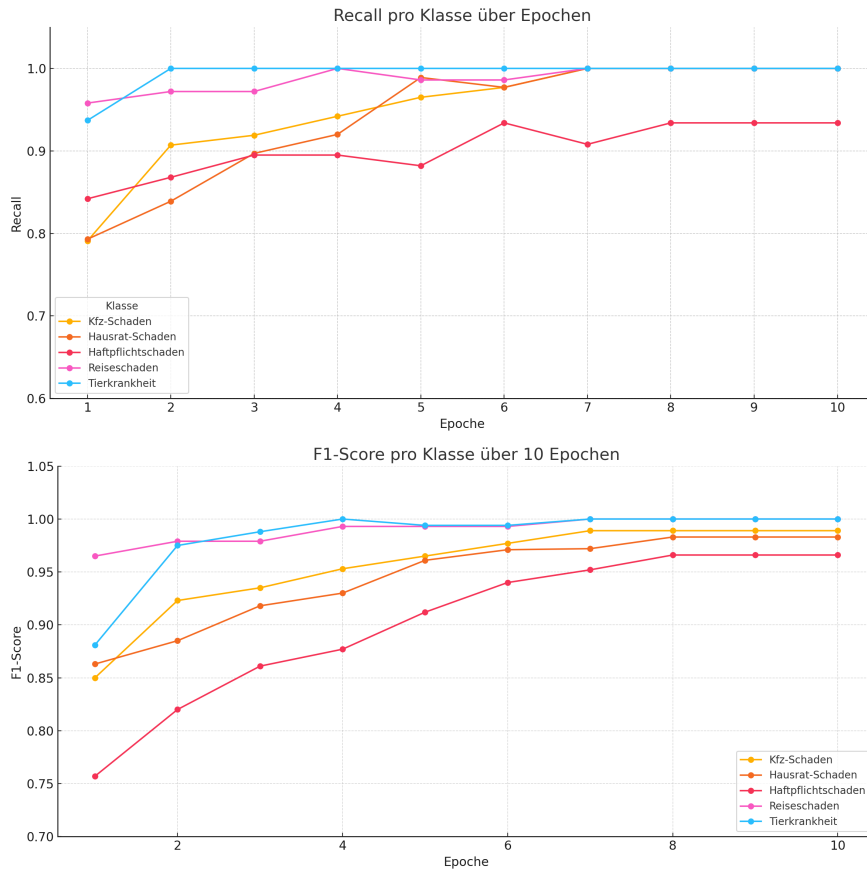
### 5.1 Allgemeine Metriken



Die erste Grafik zeigt den Verlauf der Metriken `eval_loss` und `eval_accuracy` über zehn Trainings-Epochen. Der kontinuierliche Rückgang des `eval_loss` von 1.230 auf 0.258 sowie der Anstieg der `eval_accuracy` von 0.860 auf 0.988 deuten auf ein erfolgreiches und stabiles Training hin. Das Modell generalisiert gut auf die Evaluationsdaten und konvergiert frühzeitig.

### 5.2 Label-spezifische Metriken





Diese Grafiken differenziert die Leistungskennzahlen (Precision, Recall, F1-Score) pro Klasse über den Trainingsverlauf. Besonders die Klassen *Reiseschaden* und *Tierkrankheit* erreichen ab Epoche 6 durchgehend einen F1-Score von 1.000, was auf eine nahezu perfekte Klassifikation hindeutet. Auch die übrigen Klassen, wie *Hausrat-Schaden* und *Kfz-Schaden*, zeigen eine stetige Verbesserung. Einzig *Haftpflichtschaden* startet mit geringerer Präzision, erreicht jedoch ab Epoche 7 ebenfalls sehr gute Werte. Dies unterstreicht die Effektivität des Modells im Umgang mit unterschiedlich komplexen Textklassen.

## 6 Weitere Verbesserungen

Für die ersten 2000 E-Mails erkennt das Modell schon oft die richtigen Labels, oder weist zumindest dem richtigen Label eine relativ hohe Wahrscheinlichkeit zu. Beim Nutzen des Modells fällt jedoch auf, dass dieses sich stark auf Begrüßungen und Abschied innerhalb der E-Mails bezieht, da durch die generierten Daten hier scheinbar eine Korrelation vorliegt. Wir wollen also einen weiteren Datensatz erzeugen, welcher komplett auf Begrüßung und Abschied verzichtet, sodass das Modell lernt sich auf die wichtigen Dinge zu konzentrieren. Damit das Modell trotzdem weiterhin den strukturellen Aufbau der E-Mails nutzen kann, werden wir die E-Mails jeweils mit einem besonderen [BEGIN EMAIL]-Token beginnen und mit einem [END EMAIL]-Token beenden. Wichtig wird später sein, dass wir auch bei den Nutzerdaten diese Änderung vornehmen, wir müssen also Begrüßung und Abschied extrahieren und durch diesen Token ersetzen. Im selben Zug passen wir den User Prompt weiter an, indem wir iterativ die E-Mails zu einem Label generieren, bevor wir zum nächsten Übergehen. Dadurch können wir eine höhere Variabilität garantieren. Generieren wir zum Beispiel pro Anfrage 10 E-Mails mit Label "kfz-schaden", so weiß das Modell welche Szenarien es bereits abgedeckt hat und kann somit Zuverlässiger eine Bandbreite an Szenarien generieren.

### 6.1 Verbesserter User Prompt

Bitte generiere jeweils genau **10 E-Mails** für folgendes Label im folgenden JSON-Format:

```
[
  {
    "label": "<schadenstyp>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  {
    "label": "<schadenstyp>",
    "text": "<realistische E-Mail in deutscher Sprache>"
  },
  ...
]
```

**LABEL** = {Label}

#### Regeln:

1. Die E-Mail soll **formell, aber alltagsnah** klingen – wie eine echte Nachricht von Privatpersonen oder Kunden.
2. Der E-Mailtext soll **3–4 Sätze** lang sein, in natürlichem Deutsch.
3. Verwende **keine sensiblen Daten** wie echte Adressen, Telefonnummern oder reale Versicherungsnummern.
4. Die E-Mail soll **thematisch zum jeweiligen Schadenstyp passen**, ohne zu ausschweifend oder künstlich zu wirken.
5. Verwende **normale, höfliche Sprache**, gerne mit kleinen individuellen Variationen im Ausdruck.
6. Gib **nur die Keys label und text** zurück – keine Metadaten, Überschriften oder Kommentare.
7. Ignoriere Begrüßungen und Verabschiedungen innerhalb der E-Mail, nur Szenarien
8. Jede E-Mail beginnt mit einem [BEGIN\_EMAIL]-Token der die Begrüßung ersetzt
9. Jede E-Mail endet mit [END\_EMAIL]-Token der die Verabschiedung ersetzt

#### Typische Szenarien

- "kfz-schaden" → z. B. Unfall, Blechschaden, Wildunfall
- "hausrat-schaden" → z. B. Einbruch, Wasserschaden, Brandschaden
- "haftpflichtschaden" → z. B. versehentliche Beschädigung fremder Dinge
- "reiseschaden" → z. B. Gepäckverlust, Stornierung, Krankheit im Urlaub

- "tierkrankheit" → z. B. OP beim Haustier, Tierarztrechnung

#### Thematische Richtlinien für jede Kategorie:

##### Kfz-Schaden:

- Betreff: Schäden an Autos oder Motorrädern
- Typische Begriffe: Unfall“, Fahrzeug“, Blechschaden“, Wild“, Polizei“

##### Hausrat-Schaden:

- Betreff: Schäden am Inventar in Wohnung oder Haus
- Typische Begriffe: Einbruch“, Rohrbruch“, Fernseher“, gestohlen“

##### Haftpflichtschaden:

- Betreff: Absender hat Dritten Schaden zugefügt
- Typische Begriffe: versehentlich“, mein Kind“, beschädigt“, Nachbar“

##### Reiseschaden:

- Betreff: Probleme im Urlaub, z. B. Verlust, Krankheit
- Typische Begriffe: Koffer“, Flug“, Storno“, Rechnung“, Ausland“


##### Tierkrankheit:

- Betreff: Tierarztkosten, Behandlungen von Haustieren
- Typische Begriffe: Hund“, Katze“, OP“, Tierarzt“, Rechnung“

## 6.2 Auswertung

Nach dem Generieren weiterer 1000 E-Mails mit neuer Prompt-Struktur, wollen wir uns erneut die bekannten Metriken anschauen, um Rückschlüsse über das erweiterte Fine Tuning schließen zu können.

## 6.3 Allgemeine Metriken

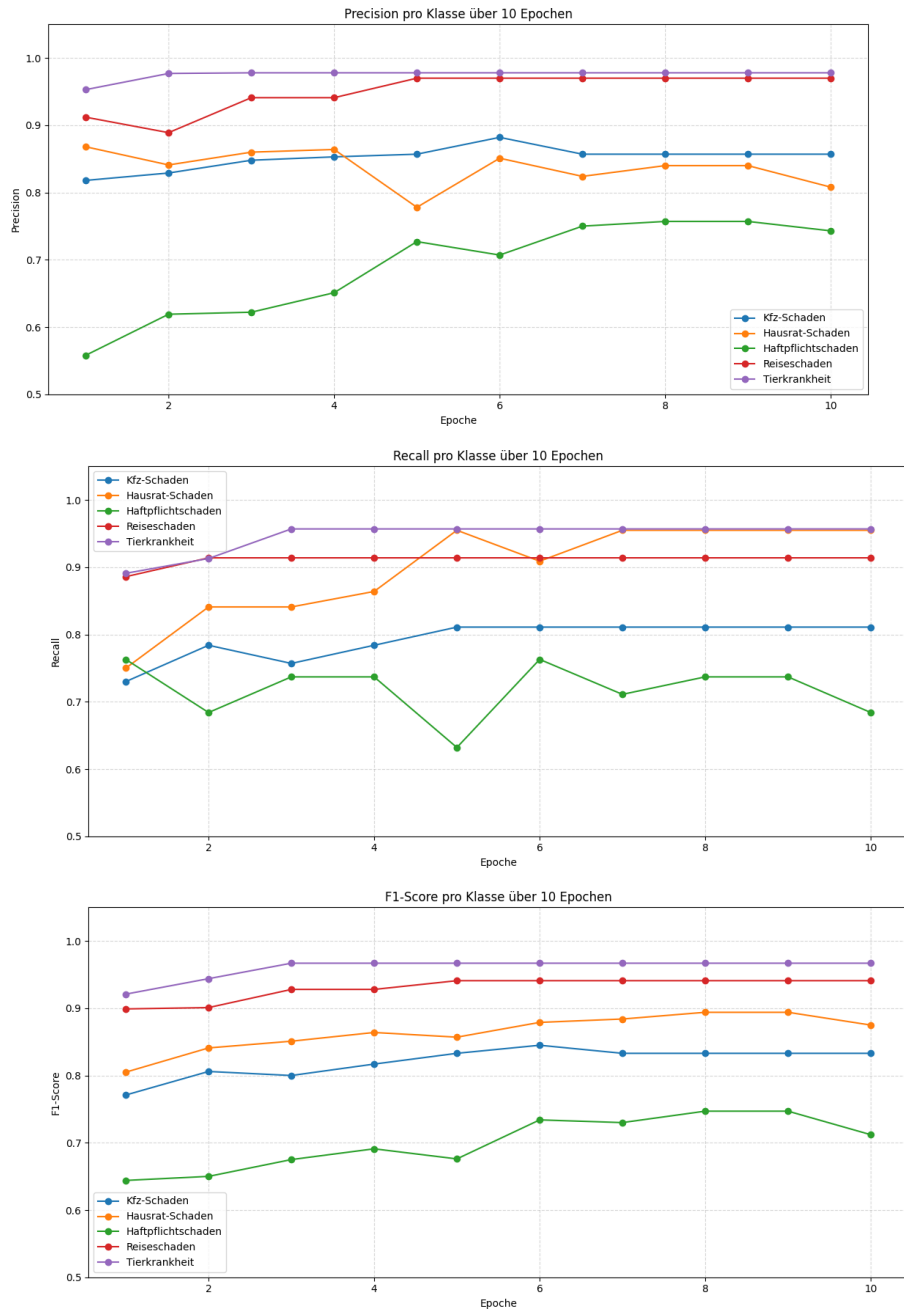


Die erste Grafik zeigt den Verlauf der Metriken `eval_loss` und `eval_accuracy` über weitere zehn Trainings-Epochen auf unseren neu generierten Daten.

Es ist ein kontinuierlicher Rückgang des `eval_loss` von anfänglich ca. 0.760 auf einen Tiefstwert von 0.554 in Epoche 9 zu beobachten, gefolgt von einem leichten Anstieg in Epoche 10 auf 0.562. Parallel dazu steigt die `eval_accuracy` von 0.805 in Epoche 1 auf einen Höhepunkt von 0.885 in Epoche 9, bevor sie in Epoche 10 leicht auf 0.870 abfällt.

Hier sind also bereits leichte Anzeichen für Overfitting in der letzten Epoche zu erkennen.

## 6.4 Label-spezifische Metriken



Auch in den Label-spezifischen Grafiken, ist grade am leichten Rückgang der F1-Werte ein leichtes Overfitting zu erkennen. Es ist zudem zu beachten, dass die in diesem Trainingslauf erreichten Höchstwerte dieser Metriken (z.B. F1-Werte von 0.941 für Reiseschaden und 0.967 für Tierkrankheit) unter den zuvor erzielten optimalen Werten (z.B. F1 von 1.000 aus früheren Iterationen) liegen. Dies lässt sich jedoch positiv interpretieren:

Die Trainingsdaten wirken auch bei manueller Überprüfung sehr viel diverser, wodurch diese Werte auch erklärbar sind. Das Modell scheint zwar insgesamt "schlechter" darin abzuschneiden, die Trainingsdaten den richtigen Labels zu zu ordnen, durch die sehr ähnliche Trainingsdaten-Struktur des ersten Trainings ist das aber zu erwarten gewesen. Trotz den nun sehr diversen Daten schneidet das Modell mehr als nur Akzeptabel ab und auch bei der praktischen Anwendung ist das zu erkennen.



Ein weiterer entscheidender Test der Generalisierungsfähigkeit des Modells war die Klassifikation von realistischen, manuell generierten E-Mails für jede Kategorie. Das Modell hat alle dieser unbekannten E-Mails korrekt klassifiziert, was die hohe Robustheit und Praxistauglichkeit des Modells unterstreicht und bestätigt, dass es auch mit natürlichen Sprachvariationen und realen Anfragen ausgezeichnet zurechtkommt.

---

## 7 Fazit, Herausforderungen und Ausblick

### 7.1 Projektzusammenfassung

Dieses Projekt befasste sich mit der Automatisierung der Klassifikation deutscher E-Mail-Anfragen für Schadenmeldungen, einem realem Problemfeld in der Bearbeitung von Kundenanliegen. Ziel war es, eingehende E-Mails effizient und präzise einer von fünf Schadenkategorien (Kfz-Schaden, Hausrat-Schaden, Haftpflichtschaden, Reiseschaden, Tierkrankheit) zuzuordnen.

Das entwickelte Modell erreichte mehr als nur zufriedenstellende Ergebnisse auf den Evaluationsdaten, mit Precision-, Recall- und F1-Scores im hohen Bereich. Besonders hervorzuheben ist die beeindruckende Generalisierungsfähigkeit des Modells, die sich in der fehlerfreien Klassifikation von realistischen, manuell verfassten E-Mails zeigte, welche dem Modell im Training nicht vorlagen.

### 7.2 Persönliche Lernerfolge

Neben der Vertiefung meiner Kenntnisse in Vue, Springboot, Docker und Python, habe ich eigenständig komplexe Konzepte wie Self-Attention-Mechanism, Tokenisierung und weitere Grundlegende Konzepte des NLP und von LLMs erlernt. Grade das Erlernen von Konzepten, die weit über das im Studium erlernte hinausgehen, hat mir gezeigt, dass ich in der Lage bin, komplexe und top-aktuelle Themen in Eigenarbeit zu erarbeiten, runterzuberechnen und zu verstehen.

Neben diesen Erkenntnissen, welche ich für meine persönliche Entwicklung als extrem wichtig erachte, habe ich zudem erstmals das Gefühl bekommen in einem, der Zeit entsprechenden, Workflow gekommen zu sein. Ich habe ein reales Problem mit Hilfe von LLMs wie Gemini, ChatGPT und anschließend BERT, sowie frei zugänglichen Ressourcen auf YouTube etc. erlernt, verstanden und gelöst. Dabei blieb mein Fokus stets auf Verständnis, sodass ich trotz dem Verwenden von LLMs auch teilweise zur Code-generierung, jede Zeile meines Projektes verstehe und erklären kann. Ich habe gelernt, wie man solch mächtige Tools für sich arbeiten lässt und diese in seinen Workflow integriert, ohne den Überblick zu verlieren oder das Gefühl zu haben das Projekt aus seinen eigenen Händen zu geben.

Auch durch das Nutzen von zum Beispiel Jules, habe ich, meiner Meinung nach, wichtige, erste Einblicke in die Zukunft des Software Engineering erreicht.

Darüber hinaus, habe ich auch viele Dinge über mich selbst gelernt, Stärken, Schwächen und vor allem in welche Richtung es für mich später weiter gehen soll:

Das Verstehen, Planen und Entwickeln von Software Lösungen mithilfe von Künstlicher Intelligenz.

### 7.3 Ausblick und zukünftige Verbesserungen

Grade das generieren von künstlichen E-Mails mit Hilfe der ChatGPT API, war ein zunächst nicht eingeplanter Schritt, dieser hat dieses Projekt jedoch noch wertvoller gemacht. Ich musste erlernen, wie man die Promp-Struktur anpasst um zufriedenstellende Diversität zu erhalten. Trotzdem wären hier natürlich echte Daten die bessere Alternative, um BERT an einen echten Anwendungsfal anzupassen und die Generalisierbarkeit zu erhöhen.

Auch das Overfitting, welches in den letzten Trainingsiterationen stattgefunden hat, lässt sich sicherlich auf die generierten Daten zurückführen, da diese, selbst bei noch höherer Diversität, niemals die vollständige Komplexität und Unvorhersehbarkeit realer Sprachmuster abbilden könnten.

Man könnte in Zukunft Nutzereingaben speichern um manuell oder autonom das Modell auf dieses weiter zu trainieren und somit die Generalisierbarkeit des Modells weiter zu verbessern.

Durch die Struktur des Projektes, vor allem die Auslagerung der Klassifizierungs-implementierung in einen

Docker-Container, sowie der Upload des Modells auf Hugging Face, sorgt für eine erhöhte Modularität, so dass dieses Modell im Prinzip in jedes bestehende System integriert werden könnte. Das war mir, trotz der natürlich eingeschränkten Generalisierbarkeit und des etwas vereinfachten Anwendungsfalls, sehr wichtig, um auch den Aspekt der Software Architekturen in diesem Projekt nicht zu vernachlässigen.